

LO17 : Indexation et Recherche d'information

TD2 : Anti-dictionnaire

Printemps 2026

Travail à réaliser

On souhaite créer les index du corpus de l'ADIT, à partir du fichier XML que vous avez réalisé dans le TD précédent. On souhaite pouvoir s'affranchir des mots qui ne sont pas porteurs de sens, tels les articles, les pronoms, les adverbes, etc, et de ceux qui n'apportent pas d'information, tels les verbes auxiliaires ou les mots très généraux. On va donc commencer par construire la liste des mots qui ne vont pas figurer dans l'index et que l'on doit supprimer du fichier XML avant de faire la lemmatisation du corpus. La construction de cet anti-dictionnaire va s'appuyer sur le calcul du coefficient tf-idf qui a été étudié en cours.

1 Choix de l'unité documentaire

Le calcul du coefficient tf-idf s'appuie sur la fréquence d'un mot dans un document et sur le nombre de documents qui contiennent ce mot. L'unité documentaire doit donc être clairement définie. Dans cette application, on a le choix suivant :

— **un document = un bulletin :**

Dans ce cas, on s'intéressera à la fréquence des mots qui apparaissent dans un bulletin, même s'ils figurent dans les titres ou textes de différents articles de différentes rubriques.

— **un document = un article :**

Dans ce cas, il faut calculer la fréquence des mots qui apparaissent dans le titre ou le texte de chaque article.

Vous devrez réfléchir aux conséquences des choix ci-dessus sur le mode de calcul du coefficient tf-idf selon l'unité documentaire choisie, sa signification et les résultats obtenus pour différents types de requêtes. **Le résultat de votre réflexion sera argumenté dans le rapport à rendre.**

2 Détermination de l'anti-dictionnaire (stop words)

Vous devez calculer le coefficient tf-idf pour chaque *token* du corpus et fixer un seuil au delà duquel les tokens seront affectés à l'anti-dictionnaire.

1. Vous écrirez une fonction **segmente** qui découpe le corpus (les titres et les textes) en tokens. Le format du résultat est un token par ligne séparé par une tabulation de son document d'origine (numéro du bulletin ou de l'article selon votre choix). Vous construirez donc un fichier qui contient trois colonnes : une colonne *identifiant_du_document* (c.à.d. le numéro du document) et une colonne *token_t*.
2. Puis, vous construirez le fichier des coefficients $tf_{t,d}$ de chaque token t dans chaque document d qui contient trois colonnes : une colonne *identifiant_du_document* (c.à.d. le numéro du document), une colonne *token_t* et une colonne $tf_{t,d}$.
3. Ensuite, vous construirez le fichier des coefficients $idf_t = \log_{10} \frac{N}{df_t}$, où N est le nombre total de documents et df_t est le nombre de documents dans lesquels le token t apparaît. Ce sera un fichier à deux colonnes *token_t*, idf_t .
4. Finalement, vous construirez un fichier à trois colonnes : une colonne *identifiant_du_document*, une colonne *token_t* et une colonne $tf \times idf_{t,d}$.

A l'issue de cette analyse, vous devrez déterminer une règle d'extraction des tokens non significatifs pour construire votre anti-dictionnaire. **Le résultat de votre réflexion sera argumenté dans le rapport à rendre.**

3 Génération du corpus filtré

Une fois l'anti-dictionnaire obtenu, vous pouvez alors éliminer ces tokens du corpus à partir de cette liste.

1. Vous écrirez une fonction `substitue` qui permet d'éliminer ou de remplacer un token par un autre dans un texte. Il prend en entrée le texte ainsi qu'un fichier de deux colonnes de tokens et de leur substitution ("" si le token est à éliminer) séparées par une tabulation.
2. Vous utiliserez la fonction `substitue` pour créer le fichier XML filtré contenant le corpus sans stop words.