

LO17 : Indexation et Recherche d'information

TD3 : Lemmatisation et Indexation du Corpus

Printemps 2026

Travail à réaliser

On souhaite créer les index du corpus de l'ADIT en créant une série de fichiers (dits fichiers inverses) permettant de décrire les documents à l'aide de tout ou partie des éléments contenus dans le fichier XML. Le résultat de l'indexation sera donc un ensemble de fichiers inverses, chaque fichier correspondant à une balise ou un ensemble de balises (date, rubrique, titre, texte, titre+texte, url des images, légende des images, ...).

L'objectif de ce TD est de normaliser le vocabulaire par lemmatisation, d'affiner l'anti-dictionnaire grâce à cette normalisation, et enfin de générer les structures de données finales du moteur de recherche.

1 Lemmatisation du corpus filtré

Nous allons utiliser des outils modernes de Traitement Automatique du Langage Naturel (TALN) en Python pour effectuer la lemmatisation sur les titres et textes du fichier XML filtré. Vous devrez évaluer deux approches :

- **spaCy** : Une bibliothèque de TALN, avec un modèle de lemmatisation français (**fr_core_news_sm**).
- **Snowball** : Contenu dans NLTK, une autre bibliothèque de TALN, utilisé pour une lemmatisation basée sur des règles de racinisation, et adapté depuis le Stemmer de Porter à la langue française.

1.1 Extraction

1. Écrivez un script Python qui applique le modèle SpaCy sur le fichier XML filtré et créez un fichier à deux colonnes contenant le mot et son lemme.
2. Répétez l'opération avec le stemmer Snowball de NLTK pour obtenir un fichier à deux colonnes contenant le mot et sa racine.

1.2 Analyse comparative et choix

Pour un échantillon de mots, comparez les résultats des deux méthodes SpaCy et Snowball. Calculez des statistiques (nombre de lemmes uniques, distribution, etc.). Quel système semble le plus adapté pour ce corpus ? Justifiez. Conservez la méthode la plus performante pour la suite.

2 Affinage de l'anti-dictionnaire

La lemmatisation regroupe plusieurs flexions sous une même forme, modifiant ainsi la distribution statistique des fréquences. Des mots ayant une fréquence individuelle trop faible pour être exclus lors de la première passe de filtrage (réalisée au TD2) peuvent voir leur fréquence cumulée dépasser le seuil d'exclusion une fois lemmatisés. Il est donc nécessaire d'affiner la liste de mots vides.

1. Reprenez l'algorithme de calcul TF-IDF fait précédemment et appliquez-le sur les lemmes (ou racines) générés à la première section pour recalculer leurs scores.
2. Observez l'émergence de nouveaux termes non porteurs de sens. Fixez un nouveau seuil pour exclure ces lemmes de l'index final.
3. Filtrez le fichier XML selon votre choix (SpaCy ou Snowball) en vous aidant de **substitutue.py**. Sauvegardez le résultat dans un nouveau fichier XML final qui servira à construire les fichiers inverses.

3 Création des fichiers inverses

Vous allez pouvoir maintenant réaliser des fichiers inverses contenant en première colonne un terme (un lemme, une date, une rubrique,...) et dans la colonne suivante les identifiants des documents dans lesquels il apparaît (bulletin ou article) ainsi que la fréquence d'apparition.

1. À partir du corpus XML lemmatisé et doublement filtré, créez un fichier inverse pour chaque balise importante, comme le titre, le résumé, la rubrique, la date, etc.
2. Comment pourriez-vous améliorer la qualité de l'indexation de ce corpus ?