

LO17 : Indexation et Recherche d'information

TD5 : Traitement des requêtes

Printemps 2026

Travail à réaliser

Vous devez réaliser un module Python qui permettra de traiter des requêtes exprimées en langage naturel saisies au clavier. L'objectif est de transformer une phrase textuelle non structurée en une représentation informatique interrogeable, en isolant les critères de recherche (dates, rubriques,...) et les mots-clés.

Écrivez un script `traitement_requete.py` contenant une fonction principale d'analyse de requête qui exécute le pipeline suivant :

1. **Extraction des métadonnées (Expressions régulières)** : Avant de découper la phrase, identifiez et extrayez les motifs complexes qui s'étendent sur plusieurs mots.
 - Les contraintes temporelles (ex : « en 2014 », « entre le 3 mars 2013 et le 4 mai 2013 », « après janvier 2014 »).
 - Les rubriques spécifiques de l'ADIT (ex : « Focus », « Horizons Enseignement », « En direct des laboratoires »).
 - Les filtres structurels (ex : présence ou absence d'images).
2. **Extraction des opérateurs logiques** :
 - Identifiez les opérateurs booléens implicites ou explicites (ex : « et », « ou », « mais pas », « sans ») qui lient les différents concepts de la requête.
3. **Traitement des mots-clés** :
 - Une fois les métadonnées et opérateurs extraits, récupérez les mots restants.
 - Faites appel à votre module de correction orthographique développé au TD4 pour tokeniser, lemmatiser, et corriger ces mots-clés.
4. **Génération de la représentation structurée** :
 - Assemblez les éléments extraits dans une structure de données standardisée (par exemple, un dictionnaire Python).
 - Exemple de sortie théorique attendue pour une requête :

```
{ 'mots_cles': ['robot', 'chirurgien'], 'rubrique': 'Focus', 'date_min': '2012', 'date_max': None, 'operateurs': ['AND'] }
```

Testez la robustesse de votre script en appelant votre fonction sur les exemples de requêtes disponibles en annexe. **Assurez-vous que la structure de données générée couvre tous les cas d'usage.**

Annexe : Exemples de requêtes

- Afficher la liste des articles qui parlent des systèmes embarqués dans la rubrique Horizons Enseignement.
- Je voudrais les articles qui parlent d'airbus ou du projet Taxibot.
- Je voudrais les articles qui parlent du tennis.
- Je voudrais les articles traitant de la Lune.
- Quels sont les articles parus entre le 3 mars 2013 et le 4 mai 2013 évoquant les Etats-Unis ?
- Afficher les articles de la rubrique en direct des laboratoires.
- Je veux les articles de la rubrique Focus parlant d'innovation.
- Je cherche les recherches sur l'aéronotique.
- Quels sont les articles parlant de la Russie ou du Japon ?
- Je voudrais les articles de 2011 sur l'enseignement.

- Je voudrais les articles dont le titre contient le mot chimie.
- Je veux les articles de 2014 et de la rubrique Focus et parlant de la santé.
- Je souhaite les rubriques des articles parlant de nutrition ou de vins.
- Quels sont les articles sur la réalité virtuelle ?
- Quels sont les articles traitant d'informatique ou de réseaux.
- je voudrais les articles de la rubrique Focus mentionnant un laboratoire.
- quels sont les articles publiés au mois de novembre 2011 portant sur de la recherche.
- je veux des articles sur la plasturige.
- je voudrais les articles liés à la recherche scientifique publiés en Février 2010.
- Donner les articles qui parlent d'apprentissage et de la rubrique Horizons Enseignement.
- Chercher les articles dans le domaine industriel et datés à partir de 2012.
- Rechercher tous les articles sur le CNRS et l'innovation à partir de 2013.
- Je cherche des articles sur les avions.
- Donner les articles qui portent sur l'alimentation de l'année 2013.
- Je veux des articles parlant de smartphones.
- Quels sont les articles parlant de projet européen de l'année 2014 ?
- Afficher les articles de la rubrique A lire.
- Je veux les articles parlant de Neurobiologie.
- Quels sont les articles possédant le mot France ?
- Je voudrais les articles avec des images dont le titre contient le mot croissance.
- J'aimerais la liste des articles écrits après janvier 2014 et qui parlent d'informatique ou de télécommunications.
- Je veux les articles de 2012 qui parlent de l'écologie en France.
- Dans quelles rubriques trouve-t-on des articles sur l'alimentation ?
- Quels sont les articles qui parlent de microbiologie ?
- Liste des articles qui parlent soit du CNRS, soit des grandes écoles, mais pas de Centrale Paris.
- J'aimerais un article qui parle de biologie et qui date d'après le 2 juillet 2012 ?
- Quels sont les articles qui parlent d'innovations technologiques ?
- Je cherche les articles dont le titre contient le mot performants.
- Je voudrais tout les articles provenant de la rubrique événement et contenant le mot congres dans le titre.
- Je cherche les articles à propos des fleurs ou des arbres.
- Articles écrits en Décembre 2012 qui parlent de l'environnement ?
- Je souhaites avoir tout les articles donc la rubrique est focus ou Actualités Innovations et qui contiennent les mots chercheurs et paris.
- Je veux les articles qui parlent du sénégal.
- Je voudrais les articles qui parlent d'innovation.
- je voudrais les articles dont le titre contient le mot europe.
- je voudrais les articles qui contiennent les mots Ecole et Polytechnique.
- Je cherche les articles provenant de la rubrique en direct des laboratoires.
- Je voudrais les articles qui datent du 1 décembre 2012 et dont la rubrique est Actualités Innovations.
- Dans quels articles Laurent Lagrost est-il cité ?
- Quels articles évoquent la ville de Grenoble ?
- Articles parlant de drones.
- Quels articles parlent de réalité virtuelle ?
- Articles parlant de molécules.
- Articles contenant une image.
- Articles parlant d'université.
- quels articles portent à la fois sur les nanotechnologies et les microsatalites.
- Lister tous les articles dont la rubrique est Focus et qui ont des images.
- Quels sont les articles dont le titre évoque la recherche ?
- Articles dont la rubrique est "Horizon Enseignement" mais qui ne parlent pas d'ingénieurs.
- Tous les articles dont la rubrique est "En direct des laboratoires" ou "Focus" et qui évoquent la médecine.
- Je voudrais tous les bulletins écrits entre 2012 et 2013 mais pas au mois de juin.
- Quels sont les articles dont le titre contient le terme "marché" et le mot "projet" ?
- je voudrais les articles dont le titre contient le mot 3D.

- Quels sont les articles contenant les mots voitures et électrique ?
- Je veux voir les articles de la rubrique Focus et publiés entre 30/08/2011 et 29/09/2011.
- Je cherche les articles sur le Changement climatique publiés après 29/09/2011.
- Quels articles parlent d'aviation et ont été publiés en 2015 ?
- Quels sont les articles de la rubrique événement qui parlent de la ville de Paris ?
- Je veux les articles impliquant le CNRS et qui parlent de chimie.
- Trouver les articles qui mentionnent Fink.
- Quels articles parlent de la France et de l'Allemagne ?
- Je veux les articles parlant de l'Argentine ou du Brésil.
- Je veux les articles qui parlent de l'hydravion.
- Je veux les articles qui parlent du fauteuil roulant et qui ont pour rubrique Actualité Innovation.
- Je veux les articles qui sont écrits en 2012 et parlent du « chrono-environnement ».
- Quels sont les articles qui parlent des robots et des chirurgiens ?
- Je veux les articles qui parlent des systèmes embarqués et non pas la robotique.
- Nous souhaitons obtenir les articles du mois de Juin 2013 et parlant du cerveau.
- Je cherche les articles qui parlent des alimentations ou des agricultures.
- Quels sont les articles dont le titre contient le mot histoire ?
- Listez-moi les articles qui parlent de 3D et qui sont écrits entre 2010 et 2011.
- Je voudrais les articles qui parlent de cuisine moléculaire.
- Quels sont les articles dont le titre contient biocarburant ou le contenu parle des bioénergies ?
- Quelles sont les articles qui concernent le CEA ?
- Je veux les articles qui parlent philosophie.
- Je veux les articles sans image.
- Retournez les articles dont le titre contient le mot nucléaire.